



Universidad Nacional del Comahue
Facultad de Informática
Departamento Ingeniería en Sistemas



Calidad y Minería de Datos

Diseño de Bases de Datos

Licenciatura en Ciencias de la Computación
3° Año

Integrantes del Grupo:

- Camila Castillo – Legajo: 4664
- Agustin Ferreyra – Legajo: 4025
- Milagros Ruiz – Legajo: 4564

Docentes:

- Prof. Titular: Agustina Buzzella
- Ayudante: Ignacio San Pedro Delgado

Neuquén - 8 de junio de 2025

ÍNDICE

SECCIONES.....	2
Unidad V.....	2
Dominio de Base Datos.....	2
Roles de la organización.....	2
Productores y consumidores de la organización.....	3
Derivación a tablas del MER.....	4
Dimensiones de atributos.....	5
Nuevas dimensiones.....	11
Interpretabilidad 1.....	11
Flexibilidad de Formato 1.....	11
Programa de calidad de datos.....	12
Etapas del plan.....	12
Mejoras en la BD tras su aplicación.....	13
Unidad VI.....	13
a. Preparación de los datos.....	13
b. Definición de un estudio.....	14
Definición.....	14
Objetivo.....	14
Aprendizaje a aplicar.....	14
c. Lectura de datos y construcción del modelo.....	15
Preparación de datos.....	15
Indicadores:.....	15
d. Compresión del modelo.....	16
e. Uso del conocimiento descubierto.....	17
Participación de estudiantes.....	17
Entre todos los participantes.....	17
Camila Castillo.....	18
Milagros Ruiz.....	18
Agustin Ferreyra.....	18
Uso de inteligencia artificial.....	18
BIBLIOGRAFÍA.....	19
[1] Data Quality: Concepts, Methodologies and Techniques.....	19
[2] Data Quality: Concepts, Methodologies and Techniques.....	19
[3] GeeksforGeeks.....	19
[4] GeeksforGeeks.....	19

SECCIONES

Unidad V

1. Elegir un enunciado de los realizados en el Práctico 1 .
 - a. Describir en el informe los requerimientos, es decir el dominio en donde va a estar implementada la BD, la estructura de la organización donde estará inmersa y los creadores y consumidores de esos datos. Lo puede hacer con un gráfico.
 - b. De cada creador y consumidor de datos en la organización deben indicar cuál es su rol y qué datos carga/usa en sus actividades cotidianas.

Dominio de Base Datos

La base de datos estará implementada en un aeropuerto y tendrá como objetivo principal realizar el seguimiento de los aviones y sus servicios de mantenimiento. Se desea registrar cada avión junto con su propietario. De cada avión se almacenará un número de registro único, el tipo de aeroplano que es, y el hangar en el que se encuentra guardado.

A su vez, se mantendrá información detallada de los hangares, registrando su número identificador, su capacidad y su ubicación dentro del aeropuerto, un hangar puede albergar varios aviones.

Cada avión está vinculado a un único propietario, del cual se almacenará un número identificador, además del nombre y apellido.

La base de datos también deberá contener información sobre los empleados encargados de realizar tareas de mantenimiento. De cada empleado se registrará su legajo, nombre y apellido.

Por último, se llevará un registro de cada servicio de mantenimiento realizado a los aviones. Cada servicio deberá estar asociado a un avión y a un empleado, indicando además la fecha de realización, la cantidad de horas dedicadas y el tipo de trabajo efectuado.

Roles de la organización

En nuestra organización contamos con los siguientes roles:

- Administrador

Un administrador será el encargado de registrar cada propietario y el avión, con su ubicación correspondiente.

Este cuando un nuevo empleado es contratado se encargará de registrarlo.

- Propietario

Cada propietario debe poder ver dónde está su avión y que mantenimientos se le realizaron

- Empleado


Cuando un empleado realiza un mantenimiento este lo debe registrar, además puede ver cuáles fueron los que anteriormente realizó

Productores y consumidores de la organización

Con los roles identificados, ADMINISTRADOR, PROPIETARIO y EMPLEADO. En la **Figura 1** se indica cómo estos roles producen y consumen datos de nuestra Base de Datos

Figura 1

Gráfico de roles de dominio




Nota: este gráfico muestra cómo, según los roles del dominio (columnas exteriores), se consumen o producen datos en nuestras tablas de la base de datos (columna central).

c. Realizar el MER y su derivación que debe resultar en no más de 4 o 5 tablas.
En la **Figura 2** se detalla el MER del dominio anteriormente detallado

Figura 2

MER resultante



Nota: este gráfico muestra las entidades que componen nuestra base de datos y cómo se relacionan entre sí.

Derivación a tablas del MER

Las tablas resultantes del MER son las siguientes:

PROPIETARIO(idPropietario, nombre, apellido)
HANGAR(idHangar, capacidad, ubicacion)
AVIÓN(nroAvion, tipoAvion, horasVuelo, idPropietario, idHangar)
MANTENIMIENTO(nroAvion, hora, tipo, fecha)
EMPLEADO(legajo, nombre, apellido)

REALIZA(nroAvion, hora, tipo, fecha, legajo)

Los atributos subrayados representan claves primarias.

Los atributos de color **rojo** representan claves foreaneas.

2. Al MER resultante deben:
 - a. Asignar las dimensiones que se quieren cumplir para cada atributo de cada tabla justificando la razón de esa asignación. Cada atributo debe contener al menos 1 dimensión

Dimensiones de atributos

Tabla 1*Dimensiones de Atributos de Propietario*

Propietario		
Atributo	Dimensión	Justificación
idPropietario	Exactitud Sintáctica :Debe cumplir el siguiente formato: 4 letras seguido un guión y luego el numero: Ej AAAA-123	Tener un único formato facilita la tarea de buscar en nuestra BD los datos de un propietario
	Compleitud:El dato no puede ser nulo	Al tratarse de la clave primaria de la entidad no puede estar vacío
nombre	Consistencia: Debe ingresar cada nombre(puede tener más de uno) comenzando con mayúscula y dejando un espacio entre medio	Para evitar que nuestra base de datos contenga datos difíciles de agrupar o interpretar utilizamos un único formato a la hora de ingresar el nombre
apellido	Consistencia: Debe ingresar cada apellido(puede tener más de uno) comenzando con mayúscula y dejando un espacio entre medio	Para evitar que nuestra base de datos contenga datos difíciles de agrupar o interpretar utilizamos un único formato a la hora de cargar el apellido
fechaCompra	Exactitud Sintáctica: La fecha debe seguir el formato correcto dd/mm/aaaa	Requerimos que la fecha siga el formato correcto para luego poder utilizarla en los cálculos

Nota: esta tabla menciona una dimensión de los atributos de Propietario con su justificación correspondiente.

Tabla 2

Dimensiones de Atributos de Avión

Avión		
Atributo	Dimensión	Justificación
nroAvion	Exactitud Sintáctica: Debe cumplir con el siguiente formato: una letra seguida de un guión y luego un número único para cada avión ej: A-12345	Tener un único formato facilita la tarea de buscar en nuestra BD los datos de un avión específico
	Compleitud: El dato no puede ser nulo	Al tratarse de la clave primaria de la entidad no puede estar vacío
tipoAvion	Consistencia: Debe ingresar el tipo de forma completa, no abreviar los tipos.	Tener consistencia en el tipo de avión facilita la agrupación de los datos en las consultas

Nota: esta tabla menciona una dimensión de cada atributo de Avión con su justificación correspondiente.

Tabla 3*Dimensiones de Atributos de Hangar*

Hangar		
Atributo	Dimensión	Justificación
idHangar	Exactitud Sintáctica: Debe cumplir el siguiente formato: dos letras seguidas de un guión y luego un número único para cada hangar. ej: BC-567	Tener un único formato facilita la tarea de buscar en nuestra BD los datos de un hangar específico
	Compleitud: El dato no puede ser nulo	Al tratarse de la clave primaria de la entidad no puede estar vacío
capacidad	Exactitud semantica:Debe representar el número real de aviones q puede almacenar	Necesitamos que el dato sea exacto para aprovechar el espacio máximo de los hangares
ubicación	Consistencia: Debe seguir el siguiente formato: país-ciudad-aeropuerto	dicho formato facilita la búsqueda de un hangar específico en nuestra BD

Nota: esta tabla menciona una dimensión de cada atributo de Hangar con su justificación correspondiente.

Tabla 4*Dimensiones de Atributos de Hangar*

Mantenimiento		
Atributo	Dimensión	Justificación
tipoMantenimiento	Consistencia: Debe ser de alguna categoría predefinida	El tipoMantenimiento debe ser uno de los tipos que ya cargados, no puede ingresar un tipo nuevo
fecha	Exactitud Sintáctica: La fecha debe seguir el formato correcto (dd/mm/aaaa)	nos interesa que la fecha sea ingresada en un único formato para facilitar la futura lectura del atributo
horas	Exactitud semántica: Debe ser la cantidad de horas reales que se hizo el mantenimiento	El tiempo representado en horas nos interesa que sea exacto para poder tener un dato preciso a la hora de realizar un estudio sobre el mantenimiento.

Nota: esta tabla menciona una dimensión de cada atributo de Mantenimiento con su justificación correspondiente.

Tabla 5*Dimensiones de Atributos de Empleado*

Empleado		
Atributo	Dimensión	Justificación
legajo	Exactitud Sintáctica: Debe cumplir el siguiente formato: tres letras seguidas de un guión y luego un número único para cada hangar. ej: TEC-111	Tener un único formato facilita la tarea de buscar en nuestra BD los datos de un empleado particular
	Complejidad: El dato no puede ser nulo	Al tratarse de la clave primaria de la entidad no puede estar vacío
nombre	Consistencia: Debe ingresar cada nombre(puede tener más de uno) comenzando con mayúscula y dejando un espacio entre medio	Para evitar que nuestra base de datos contenga datos difíciles de agrupar o interpretar utilizamos un único formato a la hora de cargar el nombre
apellido	Consistencia: Debe ingresar cada apellido(puede tener más de uno) comenzando con mayúscula y dejando un espacio entre medio	Para evitar que nuestra base de datos contenga datos difíciles de agrupar o interpretar utilizamos un único formato a la hora de cargar el apellido

Nota: esta tabla menciona una dimensión de cada atributo de Empleado con su justificación correspondiente.

- b. Investigar dos nuevas dimensiones en la literatura (no vistas en la teoría) y asignarlas también al modelo. Primero deben describirlas, colocar la referencia de donde fueron obtenidas y luego asignarlas a alguno/s de los atributos con la justificación correspondiente.

Nuevas dimensiones

Interpretabilidad [\[1\]](#)

Habilidad del usuario para interpretar correctamente valores del sistema, esto implica que los datos del sistema deben ser comprensibles para los usuarios, sin ambigüedad y con significado claro.

Avión-Tipo debe escribirse el tipo de avión de forma completa, sin abreviar palabras.

ej. no se puede ingresar Heli para representar Helicóptero.

ej2. p_y_c para referirse a pasajeros y carga.

ej3. c para referirse a un avión de carga.

Hangar - Ubicación. Se debe escribir su ubicación completa, sin abreviaturas

ej. no se debe escribir (EZ) porque aunque se puede intuir puede resultar ambiguo y confuso. en su lugar debería escribirse el nombre completo (EZEIZA).

Flexibilidad de Formato [\[1\]](#)

Es la capacidad de un sistema mostrar datos en diferentes formatos, sin perder su significado. los atributos fecha y fechaCompra pueden ser mostrados en distintos formatos como:

- 02/06/2025 (DD/MM/AAAA)
- 06/02/2025 (MM/DD/AAAA)
- 2 de junio de 2025 (formato natural)

No obstante, a la hora de cargar dichos datos estos solo podrán ser ingresados de la siguiente manera: (DD/MM/AAAA).

El atributo Ubicación de Hangar también puede poseer la flexibilidad de formato a la hora de mostrar dicho atributo, estas formas pueden ser:

- Nro_Hangar
- Ciudad, Nro_Hangar
- Ciudad,Aeropuerto,Nro_Hangar

Estos formatos pueden facilitar distintas consultas realizadas a dicho atributo dependiendo lo que necesitemos saber, si solo nos interesa trabajar con un Aeropuerto podemos solo mostrar el Nro_Hangar, para una ciudad que no posee más de un aeropuerto nos interesa ver solo la ciudad y el Nro_Hangar. si la ciudad posee más de un aeropuerto mostraremos la ciudad, aeropuerto y nro_hangar.

- c. Elegir alguno de los planes o programas de calidad vistos en teoría y describir la forma en que lo llevaría a cabo y cómo la aplicación de este plan mejoraría la calidad de la BD.

Programa de calidad de datos

Se decidió seguir con un plan de calidad de datos basado en prevención, con el objetivo de identificar las causas que generan datos erróneos y corregirlos

Etapas del plan

Para llevar a cabo este plan se organizó en las siguientes etapas

1. Identificación de causas

En esta etapa se analizaron las causas de por qué los datos almacenados no son correctos: identificando

- Cómo y por quiénes son ingresados
- Cómo son procesados
- Sus dimensiones

Podemos aclarar que esto se puede restringir a un área particular. Por ejemplo, si hay reclamos de que las fechas de los mantenimientos no son correctas, el análisis se basará en lo afectado

Su objetivo final es descubrir las principales causas de los datos erróneos, como la carga y actualización de datos no estructurados y no controlados. El resultado de este análisis de las dimensiones seleccionadas es generar un informe con la identificación de los errores [\[2\]](#)

2. Corrección de procesos

Una vez localizados los errores donde se encuentra la mala calidad, se detectara los puntos y procesos críticos y se rediseñaran

Por ejemplo se podrán tomar las siguientes medidas

- Automatizar entradas de datos para evitar errores humanos.
 - Reemplazar entradas de datos por selecciones del usuario
- Incluir validaciones en campos
 - Colocar campos obligatorios
 - Colocar rangos específicos
- Incluir puntos de control o verificación
 - Validar datos antes de seguir con otras cargas consecuentes al mismo

3. Seguimiento

El plan preventivo no es algo que se realiza una única vez, es necesario un auditoría continua que nos permita detectar errores a tiempo y aplicar las correcciones de manera temprana

Este seguimiento nos garantiza que la calidad de datos se mantenga de una forma sostenible en el tiempo.

Mejoras en la BD tras su aplicación

Con la aplicación de este plan de prevención nuestra base de datos contará con datos confiables, íntegros y de utilidad. La identificación y corrección temprana evita que se propaguen los errores.

Además la implementación de un seguimiento nos asegura una calidad de datos a largo plazo

Podemos decir que la aplicación de este plan nos asegura:

- Datos confiables para tomar decisiones en la organización
- Reducción de costos por decisiones erróneas con los datos
- Menos reclamos por parte de usuarios por errores de información

Unidad VI

1. Describir los pasos del proceso de Minería de Datos visto en teoría, pero aplicado al MER elegido en la consigna anterior.

- a. Preparación de los datos

Relacionar este paso con lo realizado en la Unidad V. Describir qué datos y variables (atributos) del MER serán utilizados. Investigar en la literatura las técnicas para el tratamiento de nulos y de valores atípicos.

Las entidades a utilizar para la minería son las siguientes:

Avion, Mantenimiento

Los atributos a utilizar son los siguientes:

De la entidad Avión: tipoAvion

De la entidad Mantenimiento: fecha horas

Para tratar con valores nulo y atípicos podemos utilizar las siguientes técnicas [\[3\]](#)

→ Eliminación

- ◆ Eliminar la fila donde se encuentra el faltante o el valor atípico

→ Reemplazo

- ◆ Métodos de imputación
 - Imputación de media, mediana y moda
- ◆ Relleno hacia adelante y hacia atrás
- ◆ Técnicas de interpolación
 - Estimación de valores faltantes basándose en puntos de datos circundantes

En caso de que el tipoAvion sea nulo obtendremos el hangar en el que se encuentra almacenado el avión y completamos el valor con el tipo de avión de otro que se encuentre almacenado en el mismo hangar.

Ya que los atributos fecha y horas de mantenimiento son claves primarias, nuestro sistema no debería tener una tabla con dichos atributos nulos.

En caso de que el atributo horas tenga valor atípico se estimara una cantidad de 2 horas promedio para el mantenimiento.

En caso de que el atributo fecha tenga un valor atípico (feriado, día no laboral, etc) se asignará la fecha habil más próxima en el calendario.

En caso de que el atributo tipoAvion se encuentre escrito en otro formato no se contemplará este valor para la minería de datos, si el dato tiene errores lexicográficos se buscará aproximar a un tipo de avión ya existente en nuestra BD realizando una interpolación comparando los caracteres y estimando en base a la cantidad de aciertos en dicha comparación el tipo del avión que se debe asignar.

b. Definición de un estudio

Indicar los objetivos y/o hipótesis que justifican la realización del proceso. Enmarcar dichos objetivos en los objetivos generales de toda aplicación de MD. Indicar qué tipo de Aprendizaje se va aplicar y justificar.

Definición

El estudio consta de observar los servicios de mantenimientos realizados a los distintos tipos de aviones, con el fin de encontrar patrones entre la cantidad de horas que toma un servicio, la frecuencia de mantenimiento y las características del avión. Con esto se busca predecir frecuencias de mantenimiento según tipo de avión, duración de los mismos según el trabajo realizado

Este estudio es en base a un rango de fechas corto para poder predecir a futuro.

Objetivo

El objetivo de realizar este proceso de minería de datos es predecir la fecha estimada del próximo mantenimiento para cada tipo de avión. Permitiéndonos anticipar las necesidades de un mantenimiento de un avión, para una planificación de recursos. Esto incluye la compra anticipada de materiales y repuestos, organización de cronogramas de los empleados y reducción de tiempos.

Aprendizaje a aplicar

Optamos por un enfoque de aprendizaje supervisado ya que tenemos una meta clara que es estimar la fecha de un proximo mantenimiento

c. Lectura de datos y construcción del modelo

Definir los indicadores que se podrían utilizar para analizar y explorar la forma en que se encuentran los datos.

Los mantenimientos a estudiar son los realizados en los últimos dos años (2024/2025), de mantenimientos registrados en la base de datos.

Tabla 6

Tabla con ejemplo de datos

Datos de BD		
TipoAvion	fecha	Horas
Jet	12/03/2025	6
Jet	12/04/2025	12
Helicóptero	25/07/2024	3
Carga	01/01/2025	4
Carga	15/01/2025	4

Nota: esta tabla contiene información de ejemplo para usar de referencia de nuestra BD

Preparación de datos

Indicadores:

- Promedio de horas de mantenimiento
- Promedio intervalo de entre mantenimiento
- Tipo de Avión

Tabla 7

Tabla ejemplo con nuestros datos preparados para la minería.

Preparación de datos		
TipoAvion	Promedio de horas	Promedio intervalo días de mantenimiento
Jet	8	30
Carga	4	100
Helicóptero	3	15

Nota: siguiendo con el ejemplo de los datos de la tabla 6 mostramos nuestros datos preparados.

d. Compresión del modelo


Definir la forma en que los datos se van a preparar finalmente para ingresar como entrada de los modelos de minería vistos.

- i. Elegir uno de los modelos e investigar alguna técnica en la literatura describiendo cómo sería aplicada en este caso. Por ejemplo, puede elegir Redes Neuronales e investigar sobre alguno de sus tipos como redes neuronales recurrentes, o redes neuronales artificiales, etc . La elección del modelo se debe corresponder con todo lo realizado previamente. Uso del conocimiento descubierto.

Elegimos utilizar el modelo de árbol de decisiones ya que nos interesa clasificar los datos de manera clara. Este modelo nos permite separar los datos en ramas hasta llegar a hojas que nos indican un resultado estimativo. En nuestro caso, estas hojas permiten estimar una fecha aproximada de mantenimiento dependiendo del tipo avion

En el árbol de decisiones mostrado en la Figura 4 se ve representado un modelo para estimar las fechas de mantenimiento de los aviones en función de varias características. Este comienza diferenciando entre los mantenimiento de los aviones realizados en el 2024 y 2025. Después seguimos ramificando por tipo de avión, permitiendo agrupar por características específicas. Luego, se utilizan los promedios de horas de mantenimiento seguido por el promedio de mantenimiento para dar con las hojas de los árboles indicándonos el estimativo del intervalo de tiempo para el siguiente mantenimiento [\[4\]](#)

Figura 3
Modelo árbol de decisiones aplicado



Nota: esta figura muestra el árbol de decisiones resultante de nuestra minería de datos. aclaración en cada nodo que tiene “..” se replica la información de su nodo hermano.

e. Uso del conocimiento descubierto

Describir cómo serán usados los resultados de la aplicación del proceso de MD de acuerdo a los objetivos propuestos y los resultados obtenidos.

El resultado de esta minería de datos nos proporcionará un atributo nuevo que será el intervalo de tiempo estimado entre el último mantenimiento con el próximo que se deberá realizar. Dicho atributo estará expresado en cantidad de días.

Gracias a esta información cada propietario podrá estimar la cantidad de vuelos a realizar antes del próximo mantenimiento, un administrador podrá organizar los futuros mantenimientos de la empresa y asignar a cada empleado el mantenimiento óptimo correspondiente a su área y su horario de trabajo.

Participación de estudiantes

Entre todos los participantes

Camila Castillo, Milagros Ruiz y Agustin Ferreyra realizaron la selección del dominio y describieron los requerimientos del mismo. Luego analizaron los consumidores y productores del dominio que actuarán en la base de datos. En conjunto desarrollaron el MER y el diagrama de consumidores productores. El objetivo de minería de datos fue decidido en conjunto por todos los integrantes del grupo.

Camila Castillo

Camila Castillo investigó en la literatura y realizó el plan de calidad de datos, etapas y beneficios tras su aplicación. También realizó una búsqueda para la aplicación del modelo de minería de datos, explicando cómo se aplicaría y realizando el diagrama de árbol de decisiones

Milagros Ruiz

Milagros Ruiz realizó la asignación de las dimensiones para cada atributo de las diferentes entidades de la unidad V. También realizó la preparación de los datos y la definición del estudio para el plan de minería de datos.

Agustin Ferreyra

Agustin Ferreyra realizó la derivación a tablas, la investigación de las nuevas dimensiones y su aplicación al modelo. Para la unidad VI realizó la lectura de datos y construcción del modelo el uso del conocimiento obtenido por la minería de datos.

Uso de inteligencia artificial

Durante la elaboración de este informe se utilizó inteligencia artificial como herramienta para la explicación de conceptos y generación de ejemplos. En particular, se recurrió a ChatGPT , con el objetivo de mejorar la claridad y coherencia.

BIBLIOGRAFÍA

[1] Data Quality: Concepts, Methodologies and Techniques

Batini C, Scannapieca M. Calidad de datos. En: Carey MJ, Ceri S, editores. *Data Quality: Concepts, Methodologies and Techniques*. Data-Centric Systems and Applications. Springer-Verlag Berlin Heidelberg; 2006. Capítulo 2, sección 2.6, p. 56.

[2] Data Quality: Concepts, Methodologies and Techniques

Batini C, Scannapieca M. Calidad de datos. En: Carey MJ, Ceri S, editores. *Data Quality: Concepts, Methodologies and Techniques*. Data-Centric Systems and Applications. Springer-Verlag Berlin Heidelberg; 2006. Capítulo 7, sección 7.2, p. 167.

[3] GeeksforGeeks

GeeksforGeeks. Handling Missing Values [sede Web]. GeeksforGeeks; 2025 [actualizado 2025; citado 2025 junio 4]. Disponible en: <https://www.geeksforgeeks.org/ml-handling-missing-values/>

[4] GeeksforGeeks

GeeksforGeeks. Decision Tree [sede Web]. GeeksforGeeks; 2025 [actualizado 2025; citado 2025 junio 4]. Disponible en: <https://www.geeksforgeeks.org/decision-tree/>